基于 ESP32 的 ChatGPT 语音交互系统设计与实现

边玉亮，毛　润，李启航，张　卓，李倩艺
（阜阳师范大学 信息工程学院，安徽 阜阳 236041）

摘　要：针对大多数用户使用 ChatGPT 主要是以网页交互的形式，为进一步扩大其实际应用范围，本文设计了一款能够实现 ChatGPT 在 ESP32 上进行语音交互的系统。选择集成 Wi-Fi、语音识别等模块的 ESP32-S3 模组，通过 VSCode 配置 Wi-Fi 和 ChatGPT-API 达到将系统接入 OpenAI 的目的，使用阿里云平台的 TTS 服务将文本结果转换成语音输出，从而实现 Wi-Fi 连接、语音交互等功能。在实际开发过程中，网络连接的不稳定和背景的噪音成为影响系统数据传输的主要因素。测试结果显示，用户分别进行长、短文本问答，系统能够准确识别提问语句，可以快速产生回答并将问题和结果在屏幕显示，达到了 ChatGPT 在 ESP32 上进行语音交互的目的，展现了系统在智能家居和智能办公等场景的应用潜力，也为用户带来了更加智能和便捷的交互体验。

关键词：ESP32；ChatGPT；Wi-Fi 连接；云平台；语音交互；语音唤醒；屏幕显示；
中图分类号：TP399　　**文献标志码：**A　　**文章编号：**2096-7020(2024)05-0020-06
收稿日期：2024-04-13　　**DOI：**10.3969/j.issn.2096-7020.2024.05.005

作者简介：边玉亮，男，安徽阜阳人，博士研究生，主要研究方向为嵌入式系统开发。

基金项目：安徽省质量工程教学研究项目（2022jyxm1178）；安徽省大学生创新创业项目（s202313619011）；阜阳师范大学信息工程学院 2023 年人才项目（2023xgrcxmz05）。

Design and implementation of ChatGPT voice interaction system based on ESP32

BIAN Yu-liang, MAO Run, LI Qi-hang, ZHANG Zhuo, LI Qian-yi
(College of Information Engineering, Fuyang Normal University, Fuyang 236041, Anhui, China)

Abstract　Given the expanding applications and influence of ChatGPT, this paper addresses the limitation of primarily web-based interactions by designing a system that enables voice interaction with ChatGPT on ESP32. The ESP32 module, integrating Wi-Fi and speech recognition capabilities, is configured with Wi-Fi SSID and password, and connected to ChatGPT via its API using an obtained API Key. The system integrates Alibaba Cloud's TTS service to convert the text responses generated by ChatGPT into speech output, thereby achieving Wi-Fi connection and voice interaction functionalities. While ESP32 can communicate with ChatGPT, unstable network connections may lead to disconnections or data transmission errors, and background noise poses a significant challenge to achieving high-quality voice interactions. To enhance communication efficiency, the system employs high-performance hardware in conjunction with real-time wake-up detection and noise suppression techniques, improving interaction accuracy and user experience. Test results demonstrate that the system can accurately recognize both long and short queries, rapidly generate responses, and display both questions and results on the screen, thereby realizing the goal of voice interaction with ChatGPT on ESP32. This not only showcases the system's potential applications in smart homes and offices but also provides users with a more intelligent and convenient interactive experience.

Key words　ESP32; ChatGPT; Wi-Fi connection; cloud platform; voice interaction; voice activation; screen display

中国知网　https://www.cnki.net

随着科技的不断发展，人工智能技术已经大规模地进入到日常生活之中。目前，国内已有多家企业和组织开始涉足 ChatGPT 技术，其中包括百度、阿里巴巴、科大讯飞、云知声等。这些企业通过对中文自然语言处理进行优化和调整，使 ChatGPT 能够更好地理解中文输入文本的含义，并生成高质量的自然语言回答。这些ChatGPT 模型在客服、虚拟助手、智能语音助手等领域具有广泛的应用前景。

ESP32 微控制器具有高精度、低功耗等特点，专为物联网和人工智能应用设计，其搭载了两个双核处理器，内置神经网络运算处理器，适用于 AIoT 领域的多种应用场景[1]。ESP32 拥有开发工具和社区的支持，活跃的开发者社区和丰富的开发资源，包括 ESP-IDF 开发框架、大量开源库和示例代码，并且以其低成本和高性能的优势，成为众多物联网项目和嵌入式系统开发者的首选。

ChatGPT 是一种新型的语言模型，不同于平常机械固定式的聊天机器人，它具有一定“智慧”，作为基于变压器架构的神经网络，已经被证明对自然语言处理任务非常有效[2]，先进的自然语言处理模型已经开始与智能语音助手技术融合，提升了语音助手的理解能力和对话自然度，支持多种语言，这使得智能语音助手能够跨越语言障碍，服务更广泛的用户群体[3]。

语音交互技术是人工智能和机器学习的一个重要分支，随着技术的进步，语音交互系统越来越能够理解和模拟人类的自然对话模式[4]，包括复杂的语言结构、口音和多种语言，以满足全球化用户的需求，并且该技术正在被集成到更多设备中，包括智能家居设备、汽车、电脑和可移动设备。

随着人工智能技术的不断完善，语音助手的功能将得到进一步拓展，同时，准确率也将得到进一步提升。目前人们大多在网页上使用ChatGPT，通过市场调查发现，一些相关产品功能比较单一，体验感较差，与“智能”两字仍有差距。结合 ChatGPT现有功能，设计了一款将ChatGPT嵌入 ESP32 进行语音交互的智能系统，该系统不仅能够实现按键唤醒、语音交互，还加入了语音唤醒、云端识别和结果显示等功能，使用户居家使用时无需动手即可与 ChatGPT 进行实时交互，为用户提供了一种全新、有趣、便捷的 ChatGPT 交互方式。

1　系统整体设计

本系统通过在 VSCode 软件上，采用 ESP-IDF 开发环境，使用基于 C/C＋＋语言的 ESP-IDF 物联网开发框架进行系统软件设计。选择 ESP32 官方提供的物联网开发框架是因为它集成了大量的软件组件，而且有官方提供的模板项目可供参考，使用起来更加便捷和高效。

系统总体框架如图 1 所示。在系统初始化完成后，系统会自动检测 Wi-Fi 是否连接成功，若成功则会进入睡眠程序，并监测用户是否触发唤醒词；若网络未连接成功，则继续尝试连接网络，直到连接成功。在成功连接云端和 OpenAI 后硬件将处于声音检测状态，然后语音识别功能将识别出的结果上传至 OpenAI，再使用 ChatGPT 生成回答后配合 TTS (Text To Speech)功能在硬件上输出语音。

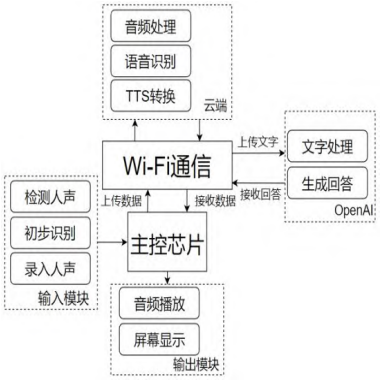

图 1　系统总体框架

2　系统硬件设计

2.1　系统硬件总体框架

系统硬件主要由 ESP32-S3 系统级集成芯片、LCD 显示屏、Wi-Fi 模块、蓝牙模块、语音识别模块等组成[5-7]。系统硬件结构如图 2 所示。该系统以 ESP32-S3 为核心，控制语音识别模块，将输入语音通过 ES7243E 芯片转换成数字信号，再通过 Wi-Fi 模块与互联网连接，将数据上传至 OpenAI，通过使用 OpenAI 的密钥与 ChatGPT 联系，再将 ChatGPT 生成的信息经云平台发送到 LCD 显示屏进行显示，与此同时，ES8156 芯片和 NS4150 芯片将数据处理后通过扬声器播放，最终完成语音对话流程。

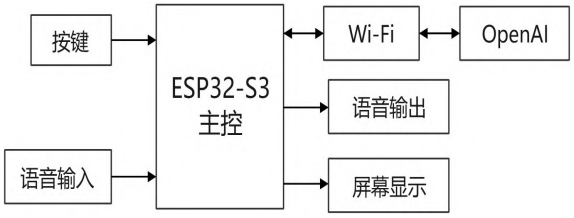

图 2　系统硬件结构框图

中国知网　https://www.cnki.net

2.2　系统主控芯片选型

本系统选择 ESP32-S3 芯片模组作为系统的控制器。ESP32-S3 是一种高效的微控制器，内置 ESP32-S3 系列芯片，其搭载了 32 位双核处理器，主频高达 240MHz，支持单精度浮点运算单元，支持高达 240 MHz 的时钟频率。除具有丰富的外设接口外，模组还具有强大的神经网络运算能力和信号处理能力，适用于 AIoT 领域的多种应用场景，例如唤醒词检测和语音命令识别、人脸检测和识别、智能家居、智能家电、智能控制面板、智能扬声器等[8]。除此之外，ESP32-S3 芯片模组还内置了 Wi-Fi 模块、蓝牙模块和板载天线，降低了外接模块的复杂性，做到在减小整体体积的同时，加快了响应速度，其能够满足本系统对硬件性能的要求[9]。

2.3　音频功率放大器硬件选型

ESP32-S3 单片机无法直接将云平台传送的数据直接输出，所以本系统选用无需滤波器的 NS4150 音频功率放大器，它是一款高性能的音频功率放大器，专为驱动小型扬声器和耳机而设计，其优异的全带宽 EMI（Electromagnetic Interference）抑制能力极大地降低了“上电”和“掉电”噪声，不仅提高了系统的稳定性，而且最大程度地减少了对其他部件的影响。音频功率放大器简单电路应用如图 3 所示。

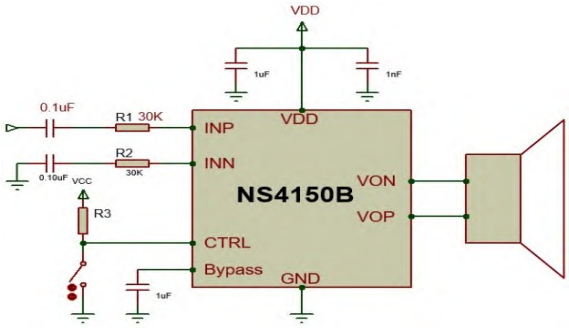

图 3　音频功率放大器简单应用电路图

2.4　Wi-Fi 模块选型

Wi-Fi 无线通信模块作为实现远程控制不可缺少的一个重要元器件，它的作用是将串口或 TTL 电平转换成符合 Wi-Fi 无线网络的通信标准。传统硬件设备中嵌入的 Wi-Fi 通信模块可以直接利用 Wi-Fi 联入互联网，是实现数据上传云平台、M2M（Machine to Machine）等物联网应用的重要组成部分[10]。

2.5　语音识别模块选型

通过使用 ES7243E 语音芯片以及高性能的立体声音频模数转换器，如图 4 原理所示，ES7243E 语音识别芯片可将语音转为数字信号，再通过 I2C 协议传输入主控芯片。该芯片可应用于麦克风阵列、音响、数字电视、音频接口、音频接收器等场合，还可搭配摄像头更好地实现远场拾音和消除回声功能。

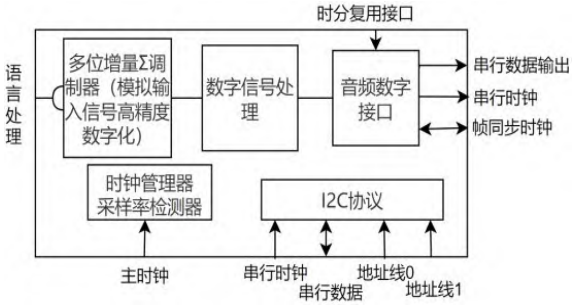

图 4　ES7243E 语音识别芯片原理示意图

3　系统软件设计

3.1　搭建程序开发环境

3.1.1　开发环境介绍

选择乐鑫公司开发的 ESP-IDF 作为程序开发框架，它是一个开源的软件开发框架，基于 C/C++语言提供的一个自给自足的 SDK（Software Development Kit）软件开发工具包，帮助开发者快速构建基于 ESP32 和 ESP32-S 系列的应用。ESP-IDF 提供了完善的文档和示例代码，能够使开发者快速上手开发，并且拥有庞大的开发者社区，开发者可以在社区中获得技术支持、交流经验和分享创意。

VSCode（Visual Studio Code）是由微软开发的免费开源的跨平台集成开发环境（IDE），旨在提供轻量级但功能丰富的代码编辑和开发工具。它不仅支持多种编程语言，还提供了丰富的扩展系统，使开发者能够根据自己的需求定制和扩展其功能。VSCode 拥有丰富的插件生态系统，可以方便地安装和配置各种插件来支持 ESP-IDF 的开发，例如 C/C++插件、Git 插件、调试插件等。

本文在 VSCode 上使用乐鑫的 ESP-IDF 提供的优秀的集成开发环境和丰富的扩展支持，方便代码的编辑、编译、串口监视，并且支持在线烧录等功能，有利于提高效率和使用体验。

3.1.2　开发环境搭建

本文采用 VSCode 1.85.1 版本，ESP-IDF 5.1 版本进行编程。在使用 VSCode 前需要事先安装离线版 ESP-IDF，然后在 VSCode 中安装插件。在 VSCode 中配置 Espressif IDF 插件时选择

中国知网　https://www.cnki.net

“Use Existing Setup”，再选择已安装好的离线版 ESP-IDF，之后等待“All Settings Have Been Configured”界面出现，若界面出现即可说明已成功安装开发环境。

3.2　界面 UI 设计

3.2.1　软件介绍

Squareline 是一款可视化的拖放式 UI 编辑器，它集合了众多实用功能，可以帮助用户轻松制作出各种精美的设计作品。此外，Squareline 还提供了许多精美范例供使用者参考，同时也可以在范例的基础上加入自己的修改，制作出符合自己想法的 UI 界面。与此同时，Espressif 官方在文章中指出，部分 ESP32 单片机可使用此软件制作界面，并且制作出的界面可以导出 UI 文件，之后可在 ESP-IDF 软件中和其他示例项目一样直接编译并将代码烧录单片机中。这是我们选择这款软件最主要的原因。总之，Squareline 是一款非常强大的平面设计软件，它具有丰富的功能和工具，并且有着良好的易用性和可自定义性。

3.2.2　UI 设计结果

在 Squareline 软件中设计好 GUI 后，导出对应不同界面的 UI 设计代码文件，但是这时的代码不能直接使用，需要移植后才能够正常使用。首先选择设备型号，然后在 ESP-IDF 官方例程中寻找 image_display 进行移植，将设计好的 GUI 改写成函数，在目录中的 image_display.c 中的 app_main()调用，再根据显示结果调整屏幕大小、解决编译报错等问题。

3.3　核心模块程序设计

3.3.1　Wi-Fi 连接功能

Wi-Fi 连接功能主要用于将互联网与系统硬件连接，连接功能流程如图 5 所示。系统设计上电后自动搜索 Wi-Fi 的 SSID 并输入密码，成功连接后可访问互联网。

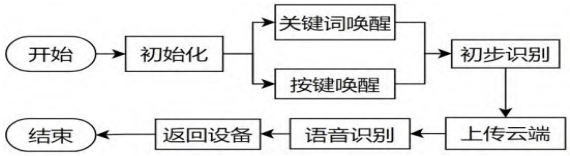

图 5　Wi-Fi 连接功能流程图

3.3.2　语音识别功能

语音识别功能主要用于将语音转化为文本，本设计通过识别模块来实现此功能。如图 6 语音识别功能流程图所示，用户通过说出预设的唤醒词或按下设备上的物理按键来唤醒设备。设备被唤醒后随即开始识别声音，并对声音进行持续监控[11-12]。当检测到语音输入结束时，停止识别声音，然后将识别文件上传至云端进行分析，分析后的结果再返回到硬件设备，供后续处理和使用。

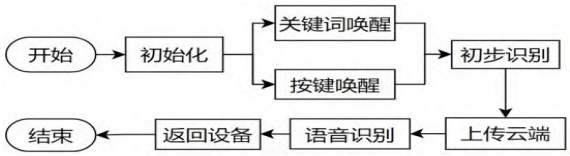

图 6　语音识别功能流程图

3.3.3　ChatGPT 功能调用

ChatGPT 功能调用流程如图 7 所示。首先访问 OpenAI，在 OpenAI 官方网站获取到 API-key，使用乐鑫官方提供的 OpenAI 组件添加到项目中，云端分析后的文本会上传至 OpenAI 公司提供的 ChatGPT-API 中，ChatGPT 接收后会生成应答结果，最后返回硬件设备中播放。

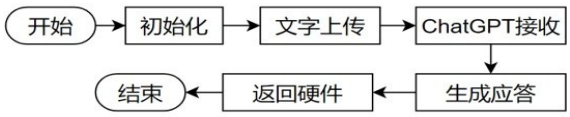

图 7　ChatGPT 功能调用流程图

3.3.4　TTS 语音转文本功能

TTS 是将文字转化为语音的技术，该技术是本设计的重要组成部分[13]。其主要分为语言分析部分和声学系统部分。语言分析部分主要是根据输入的文本信息进行解析，生成与之对应的语言规格；声学系统部分主要是根据语音分析部分提供的语言规格，生成对应的音频并播出。

本项目使用阿里云平台的 TTS 功能，将 ChatGPT-API 接收的文本上传云端后转换成音频文件再发送到硬件设备上通过扬声器模块播出，并在屏幕上显示文本，完成整个语音识别到语音应答的过程[14-15]。语音分析部分流程如图 8 所示。

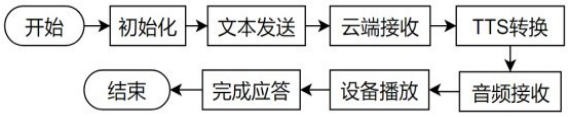

图 8　语音分析部分流程图

3.4　实时唤醒问题及解决

VAD(Voice activity detection)是一项用于语音处理的技术，目的是检测语音信号是否存在，主要用于语音编码和语音识别。它可以简化语音处理，也可用于音频会话期间去除非语音片段。VAD 算法的经典设计如下：首先是一个降噪过程；然后对输出信号的一个区块提取特征；最后使用一个分类器对这个区块进行分类，判断是否是

中国知网　https://www.cnki.net

语音信号[16-18]。在上面这个过程中通常有一些反馈过程，这时使用 VAD 系统的决策功能可更好地估计和去除噪声，或者适应性的调整阈值。这些反馈操作可以在一定程度上识别和减少非稳态噪声的影响，比如噪声的差异很大时。

在系统调试过程中，发现语音识别在无人唤醒时一直处于检测声音状态，这就导致了系统会识别许多无效的内容，而且还会增加功耗。针对此问题，本设计在系统部分代码里加入了唤醒检测算法。系统使用 WakeNet 唤醒词算法制作了一个唤醒检测，当系统被唤醒后，唤醒检测算法可以进行语音检测，当停止说话后，唤醒检测识别并且系统停止检测。同时我们也加入了 VAD 剔除噪音算法。此算法可以从一段纯净或者嘈杂的语音中准确地识别出人类的语音片段，这样既解决了实时检测语音的问题，又优化了精准识别内容的能力[19-20]。

4　系统主要功能测试

4.1　Wi-Fi 功能测试

Wi-Fi 连接到互联网。由于 ESP32-S3 只能识别 2.4GHz 的 Wi-Fi 频率，所以需要在路由器中设置 2.4GHz。需要注意的是，Wi-Fi 的 SSID 要简洁明了，最好是字母加数字，PASSWORD 同理，字母加数字的格式会大大提高安全性[21]。程序设计了在未连接成功 Wi-Fi 前的持续等待，一旦连接成功，就会在屏幕显示连接成功字样。

4.2　语音识别功能测试

通过配置好的程序来实时检测唤醒词，设备被唤醒后开始识别声音，识别出的文本会通过屏幕显示出，当无声音发出后，系统会上传信息产生应答，在此期间，需要等待应答返回。图 9 所示为正在生成结果。

图 9　正在生成结果

4.3　TTS 功能测试

本设计使用阿里云平台的 TTS 功能，将 ChatGPT-API 接收的文本上传云端后转换成音频文件再发送到硬件设备上通过扬声器模块播出，并在屏幕上显示文本，完成语音识别到语音应答的全过程，短文本与长文本问答结果分别如图 10、图 11 所示。

图 10　短文本问答结果显示

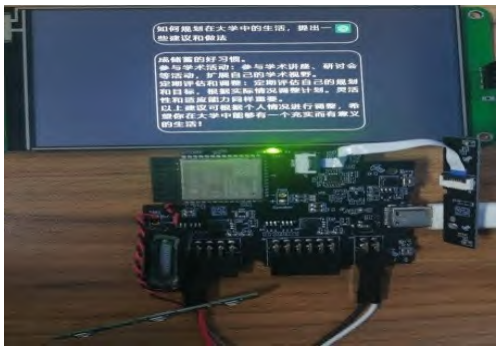

图 11　长文本问答结果显示

5　结论

ChatGPT 的传统使用方法通常是以网页的形式或者在使用相关的产品时，需要先按下特定的按键，才能进行下一步操作，不便与用户实时交互操作。针对上述问题，设计开发了一款基于 ESP32 实现的 ChatGPT 语音交互系统。系统简化了用户操作流程，能够实现用户与 ChatGPT 之间清晰、快速的交流，为用户提供自然、流畅的对话体验。通过本研究获得以下成果：

(1)该系统能够实现语音信息处理、ChatGPT 语音实时对话以及文本显示和语音输出等功能，同时具有更高的响应速度和效率，提高了用户交互的实时性和流畅度。

(2)系统在保留按键唤醒功能的基础上，增加了语音唤醒词唤醒功能，通过唤醒词唤醒的方法，不仅提高了系统的智能化水平，还大大地降低了系统的功耗。

(3)系统加入了 VAD 降噪算法和 WakeNet 唤醒词算法，进一步提高了系统语音唤醒和语音识别的准确性和可靠性。

中国知网　https://www.cnki.net

参考文献：

[1]燕越，刘忠超，刘尚争，等.基于 ESP32 与 STM32 的无线智能监控小车设计[J].中国仪器仪表，2023(11)：42-47.

[2]邓玉华.ChatGPT 的现况及人工智能在医学教育中的应用展望[J].中国继续医学教育，2024，16(5)：195-198.

[3]唐永军.基于深度学习的智能语音助手研究[J].现代信息科技，2021，5(12)：75-79.

[4]薛雅洁，贺红霞，杨祎.基于神经网络的语音信号识别与分类[J].现代电子技术，2023，46(24)：79-84.

[5]谭伟伟.基于 ESP32S3 的智能家居控制面板系统设计[J].电子产品世界，2023，30(8)：79-81.

[6]王爱利.基于 ESP32 的智能家居系统的设计与实现[D].沈阳：沈阳师范大学，2023.

[7]张靖. 基于 ESP32 的泥石流灾害监测预警系统设计[D].武汉：武汉工程大学，2023.

[8]宗和刚，沈唯羽，安美惠，等.基于 AI 语音识别芯片的水电站检修小灯设计与实现[J].水电站机电技术，2023，46(11)：124-126.

[9]张来洪，卢继川，关海伟，等.单兵电台基于 ESP32 扩展 Wi-Fi 及蓝牙功能[J].电声技术，2023，47(3)：99-103.

[10]代敏，李小静，利洁雯.基于物联网的单片机远程控制智能家电系统的实现[J].产业创新研究，2023(20)：106-108.

[11]唐曼玲.基于语音识别的快递信息采集系统[D].成都：成都理工大学，2019.

[12]邓鑫. 基于语音识别的控制终端设计[D].西安：西安工程大学，2020.

[13]王维虎，刘嘉成.基于文本语音混合模式的家庭生活垃圾分类的研究[J].湖北工程学院学报，2023，43(6)：97-101.

[14]杨培康，陈宣睿，肖峰.基于 ESP32 与阿里云平台的智能风扇[J].产业创新研究，2024(4)：68-70.

[15]高梓枫. 端到端中文语音合成的研究与实现[D].北京：北京邮电大学，2022.

[16]虞秋辰. 基于深度学习的语音唤醒词检测方法研究[D].北京：北京建筑大学，2023.

[17]赵兴强.基于语音识别的数据输入通用系统的开发[D].北京：北京林业大学，2018.

[18]赵伊伊.基于在线学习视频内容的学生专注力判断模型的研究与实现[D].北京：北京邮电大学，2020.

[19]李继超，贺晓倩，权亚腾，等.一种室内智能语音识别垃圾分类系统的设计[J].自动化与仪表，2021，36(11)：103-108.

[20]刘余.基于神经网络特征映射的声纹识别技术研究与实现[D].成都：电子科技大学，2021.

[21]杨明杰，陈键森，肖振豪.基于手机 WiFi 的教学楼照明远程节能控制器[J].山西大同大学学报(自然科学版)，2023，39(6)：26-30.

责任编辑　喻晓敏

(上接第 4 页)

红安的探索与实践证明，以“劳动教育为体，综合实践为用”，整体规划实践课程、项目化开展活动、构建实践育人体系这一课程建设与实施策略，能充分发挥劳动教育与综合实践活动课程的育人功能，是学校自主推进劳动教育与综合实践活动两门课程校本化建设、落实“五育并举”育人理念的有效途径。这一模式不仅具有显著的教育成效，还为其他学校的课程融合提供了宝贵的经验和启示。

参考文献：

[1]中华人民共和国教育部.义务教育课程方案(2022 年版)[M].北京：北京师范大学出版社，2022.

[2]中华人民共和国教育部.中小学综合实践活动课程指导纲要(2017 年版)[M].北京：北京师范大学出版社，2017.

[3]中华人民共和国教育部.劳动课程标准(2022 年版)[M].北京：北京师范大学出版社，2022.

[4]李绪明.新时代中小学劳动课程的构建与实施[J].课程·教材·教法，2020，40(5)：16-21.

[5]卢丽华，于明业.基于新时代构建中小学劳动教育课程[J].中国德育，2020(2)：7-10.

[6]余向红.小学综合实践活动课程规划与实施例谈[J].黄冈师范学院学报，2020，40(1)：70-73，106.

[7]王玉梅.新时代中小学劳动教育课程体系构建探索[J].新课程导学，2022(20)：32-34.

[8]徐爱枝.语言表达能力与项目式劳动教育的融合路径——以义务教育统编版教材四年级《语文》(上册)为例[J].黄冈师范学院学报，2023，43(1)：76-81.

责任编辑　王菊平

中国知网　https://www.cnki.net